



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
ESCUELA DE INGENIERÍA  
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS  
ICS2122 – TALLER DE INVESTIGACIÓN OPERATIVA  
PROFESORES: GONZALO PÉREZ, MARCELO PÉREZ, ARIEL ESPINOZA, MATÍAS DE GEYTER,  
ELBIO AVANZINI, ALEJANDRO MAC CAWLEY  
AYUDANTE JEFE: FRANCISCO TAMARÍN  
SEGUNDO SEMESTRE 2023

## Informe 2

---

### Mantenimiento predictivo mediante datos categóricos de una línea de embotellado

---

#### Grupo 5

TOMÁS ARANCIBIA  
CONSUELO HONORATO  
FLORENCIA LIRA  
ANTONIA ORREGO  
RAFAELA RÁMIREZ  
MACARENA TAGLE  
GASPAR VILLARROEL

# Índice

<b>1</b>	<b>Resumen Ejecutivo</b>	<b>3</b>
<b>2</b>	<b>Introducción</b>	<b>3</b>
<b>3</b>	<b>Descripción del problema</b>	<b>4</b>
3.1	Antecedentes . . . . .	4
3.2	Exploración de datos . . . . .	5
<b>4</b>	<b>Discusión Metodológica</b>	<b>6</b>
4.1	Metas e Indicadores clave . . . . .	6
4.2	Método de Redes Neuronales Recurrentes . . . . .	6
4.3	Métodos de Suavización Exponencial . . . . .	7
4.3.1	Método de Suavización Exponencial Simple (SES) . . . . .	7
4.3.2	Método Holt-Winters . . . . .	8
4.4	Fast Fourier Transform . . . . .	8
4.5	Comparación de metodologías . . . . .	8
<b>5</b>	<b>Análisis de datos</b>	<b>9</b>
5.1	Frecuencia . . . . .	9
5.2	Avisos y Alarmas . . . . .	10
5.3	Producción . . . . .	12
5.4	Status . . . . .	13
<b>6</b>	<b>Metodología</b>	<b>13</b>
6.1	Estudio de los datos . . . . .	14
6.1.1	Definición de Falla . . . . .	14
6.1.2	Relaciones extraídas . . . . .	15
6.1.3	Caso base . . . . .	15
6.1.4	Correlaciones . . . . .	15
6.1.5	Clusterización . . . . .	18
6.2	Modelo de predicción: . . . . .	20
6.2.1	Predicción Mediante RNN . . . . .	21
6.2.2	Desarrollo y entrenamiento del modelo: . . . . .	21
6.3	Validación del modelo . . . . .	21
<b>7</b>	<b>Propuesta de política</b>	<b>22</b>
<b>8</b>	<b>Pasos a seguir</b>	<b>22</b>
<b>9</b>	<b>Conclusiones</b>	<b>23</b>
<b>10</b>	<b>Referencias Bibliográficas</b>	<b>24</b>
<b>11</b>	<b>Anexos</b>	<b>25</b>
11.1	Carta Gantt . . . . .	25
11.2	Anexo 1 . . . . .	25
11.3	Anexo 2 . . . . .	26

11.4 Anexo 3 . . . . .	27
11.5 Anexo 4 . . . . .	28
11.6 Anexo 5 Gráficos frecuencia status . . . . .	30
11.7 Anexo 6 . . . . .	38

# 1 Resumen Ejecutivo

En el presente informe se desarrolla un análisis detallado sobre el trabajo de investigación realizado con la línea de embotellamiento de vinos de una empresa vitivinícola. El objetivo es actualizar las políticas de mantenimientos ya existentes, pasando de uno preventivo/correctivo hacia uno predictivo, el cual busca mejorar la eficiencia operativa y la gestión del mantenimiento de la máquina automatizada.

El proyecto está sustentado en datos de tipo categóricos, los cuales están presentes en cinco bases de datos distintas: avisos, alarmas, mantenciones, status y producción. Estas contienen información de distintas ocurrencias en un periodo de 20 meses, juntando entre ellas mas de 5 millones de observaciones.

Gracias a la investigación de las bases de datos en conjunto, se pudo analizar el comportamiento de las ocurrencias de la maquinaria con respecto a las mantenciones realizadas, y se pudo observar que las mantenciones se realizaban una vez que ésta fallaba. De aquí surge la importancia de resolver este problema, ya que fallas en la línea implican pérdidas de materia prima, tal como lo son las botellas y el vino.

A partir de esto, se establecen metas a cumplir e indicadores que permitan medir el desempeño, para poder testear la eficiencia de distintas metodologías de predicción. Se utilizará finalmente una predicción basada en un enfoque 50/25/25, para dividir los datos en entrenamiento, validación y pruebas.

Para esto, se analizan y discuten distintas metodologías encontradas en la literatura, incluyendo las redes neuronales recurrentes, métodos de suavización exponencial, método Holt-Winter, método de Croston y SBA y Fast Fourier Transform. Se investigó sobre fortalezas y debilidades de cada metodología y se realizó un análisis comparativo para determinar que metodología se adapta mejor a la resolución de la problemática, poniendo énfasis en la complejidad y tamaño de los datos, parámetros a estimar y variables endógenas y exógenas. A partir de ese análisis se llegó a la conclusión de que la mejor metodología eran las Redes Neuronales Recurrentes.

Según la selección de metodología, se contó con una nueva base de datos la cual aportó a la exploración de datos y alcanzar relaciones adicionales entre avisos, alarmas, status de la máquina y la producción con lo mantenimientos. Con todo esto, se destacaron dos avisos; “Máquina ligeramente desfasada” y “Máquina desfasada” considerándolos como catastróficos lo cual contribuyó en la definición de falla y así asentar un caso base, se observó que la frecuencia era baja pero crítica para la producción.

Se llevó a cabo análisis de correlación y autocorrelación para comprender el comportamiento de las ocurrencias en conjunto y analizar efectos causales, como también, clusterización para agrupar eventos relacionados.

Luego de un profundo análisis de datos, se pudo desarrollar el modelo de predicción de fallas en la línea de embotellado mediante las RNN para el caso base, describiendo los pasos de testeo, desarrollo y entrenamiento, llegando a grandes resultados de la precisión y pérdida durante el entrenamiento del modelo.

Con la comparación de las ocurrencias reales con las predicciones se logró obtener la validación del modelo, concluyendo que los resultados no eran óptimos debido a la limitada cantidad de datos, lo cual da esperanza para los pasos futuros al extrapolar a datos adicionales.

Finalmente, se propuso la implementación de política para mejorar la calidad e integridad en la medición de datos, con el fin de diferenciar claramente entre avisos y alarmas y poder definir de manera temprana una posible falla, catalogándolos de manera precisa.

## 2 Introducción

En el entorno de los procesos productivos empresariales, la optimización y agilización de la producción son pilares fundamentales para satisfacer la demanda y alcanzar una máxima rentabilidad. Sin embargo, estos objetivos pueden verse amenazados por las incidencias en los recursos operacionales, específicamente en la maquinaria responsable de los procesos de la empresa, lo que impulsa la necesidad de una aproximación mas exacta a los momentos en que se requiere de un mantenimiento, y así disminuir los periodos de inoperancia.

Los sistemas de embotellado, con su maquinaria especializada y ritmo constante, están sometidos a un desgaste que puede llevar a fallas costosas y tiempos de inactividad no planificados, que pueden significar la pérdida de materia prima y el no cumplimiento de la demanda. Si se cuenta con un sistema de mantenimiento correctivo o preventivo, como es el caso de la empresa en cuestión, no se está abordando de manera óptima las fallas imprevistas y los recursos, lo que puede resultar en tiempos de inactividad, gastos innecesarios y falta de capacidad para prever y evitar problemas críticos de manera anticipada. En la actualidad, numerosas organizaciones están optando por estrategias de mantenimiento predictivo por una serie de razones fundamentadas. El enfoque de mantenimiento predictivo se basa en la utilización de datos históricos y técnicas de análisis para prever posibles fallos en la maquinaria antes de que ocurran. Además

de prolongar la vida útil de los equipos, es una herramienta esencial para prevenir las interrupciones no planificadas, reducir costos operativos y garantizar un óptimo funcionamiento que conlleve a una mayor seguridad en los procesos productivos.

Ahora se cuenta con el desafío de desarrollar una metodología de mantenimiento predictivo para la línea de embotellamiento de una empresa vitivinícola, cuyo nombre aun no se sabe. Para lograrlo, se cuenta con bases de datos que contienen un gran volumen de información registrada en los últimos veinte meses. Esta tarea implica la aplicación de algoritmos y modelos avanzados de análisis de datos para identificar patrones, tendencias y señales tempranas de problemas o anomalías. A medida que se avanza en la investigación, se cree que el enfoque en el mantenimiento predictivo ofrecerá beneficios significativos para la empresa y contribuirá al éxito continuo de la línea de embotellamiento en este mercado altamente competitivo. En las secciones siguientes de este informe, se detallan los pasos que se han seguido y los que quedan por cumplir, con el objetivo de proporcionar una visión completa del trabajo realizado y sus implicaciones para el proceso de embotellamiento.

## 3 Descripción del problema

### 3.1 Antecedentes

Una línea de embotellamiento de vinos consta de 4 etapas; enjuague, lavado y secado, llenado y tapas. Siguiendo un proceso de Monoblock en una máquina automatizada, con una serie de estaciones con eventos y operaciones de manera secuencial. Cada evento presente en un proceso de embotellamiento en empresas vitivinícolas, es de suma importancia para lograr un procedimiento eficiente y eficaz. Es por esto que es necesario analizar cada una de estas y cómo afectan a la producción cuando se generan distintos tipos de fallas.

Actualmente, esta empresa hace uso de un modelo de mantenimientos preventivos el cual se basa en hacer mantenimientos periódicos antes de que ocurra la falla, por lo que, al no ocupar el 100% de la capacidad de la máquina, se crea un costo adicional considerable en la utilidad de la empresa. Sin contar, que a la hora de analizar su implicancia en las bases de datos, estos solo se realizan por una cierta cantidad de horas transcurridas de la máquina en funcionamiento, por lo que no es considerado en el modelo que se plantea a futuro, ni en el análisis de datos. Además, en caso de que la máquina presente una falla imprevista, la embotelladora toma una postura correctiva, realizando una mantención a producción cero, afectando directamente los volúmenes productivos de la empresa. Esto trae consigo bastantes consecuencias perjudiciales en la eficiencia operativa de la línea de embotellamiento. Si bien, se reduce el riesgo de fallas inesperadas, los recursos son limitados, por ende, esto puede generar costos de recursos y utilidades donde no son estrictamente necesarios. El modelo correctivo, por otro lado, detiene la línea de producción dificultando la capacidad de satisfacer la demanda del mercado en el tiempo solicitado.

La detección y gestión de defectos es crucial en el ámbito del correcto funcionamiento de la línea productiva, debido a las enormes pérdidas económicas y de recursos que pueden generar, incluso si algunos de esos defectos resultan ser falsas alarmas. Existe un claro trade-off entre las tres metodologías de mantenimiento mencionadas con anterioridad. Por un lado, el mantenimiento correctivo implica abordar las fallas una vez que se detectan, lo que puede ser costoso y peligroso si la detección es tardía. Por otro lado, el mantenimiento preventivo se basa en programar revisiones periódicas de componentes en función de su edad, lo que puede ser efectivo en casos donde la probabilidad de falla está relacionada con la edad del equipo, pero puede llevar a un mantenimiento repetitivo e innecesario en otros casos.

Para superar estas limitaciones y anticipar defectos mientras se evitan mantenimientos innecesarios, se introduce el mantenimiento predictivo. Esta metodología se basa en datos en tiempo real y datos históricos para estudiar y comprender las causas de los defectos. El objetivo es identificar las condiciones que generan defectos y, si los resultados son prometedores, se busca encontrar el equilibrio entre la detección temprana de defectos y la minimización de mantenimientos innecesarios en la maquinaria (Lopez, 2021).

La empresa vitivinícola en cuestión cuenta con una gran recopilación de datos ordenados, tanto categóricos como continuos, que ha utilizado para optimizar su operación en la línea de embotellamiento. Para esto, es necesario también hacer cuenta de los mantenimientos que se deben realizar, y minimizar su ocurrencia, ya que estos significan detener la producción. Al observar los datos entregados, los mantenimientos que se realizan no cuentan con ningún tipo de periodicidad definida, por lo que es necesario definir un mantenimiento predictivo en base a la información entregada, con el fin de contar con un modelo proactivo de mantención en base a las necesidades específicas según las condiciones del contexto operativo y así maximizar la productividad en la línea.

## 3.2 Exploración de datos

Para el análisis de datos se dispuso de 5 bases de datos. Algunos elementos comunes que poseen estas bases de datos es el registro temporal el cual al hacerlas coincidir definen el marco temporal de estudio desde el 06/09/2022 hasta el 14/06/2023, es importante mencionar que se está trabajando con una máquina en específico de la marca “Bertolaso”, por lo que la gran mayoría de los datos son generados por ella o se encuentran relacionados a ella. Los únicos datos que no son obtenidos directamente de la máquina son las fechas de las mantenciones, las cuales fueron proporcionadas directamente por la empresa.

A continuación se detallan cada una de las bases de datos:

**Alarmas:** Esta base de datos corresponde a información entregada por la máquina que muestra la ocurrencia de estos eventos denominados alarmas en varios instantes de tiempo, este tipo de evento se caracteriza por mostrar un cambio en el comportamiento de la máquina que debe ser considerado según su gravedad, ya que se registran desde ocurrencias de rutina hasta fallas que significan su mal funcionamiento. Esta posee una longitud de 14,952 observaciones, de las cuales se logró extraer un total de 81 alarmas distintas, las cuales se encuentran detalladas en el Anexo (1). En particular esta base posee una columna denominada causa la cual clasifica las alarmas en 6 tipos: “No Asignado”, “Generic Cause”, “Internal Cause”, “External Cause”, “Operator Action”, “Outfeed Accumulation”

**Avisos:** Esta base de datos sigue el mismo comportamiento que la base de alarmas, es un registro en el tiempo de la ocurrencia de eventos que se catalogan como avisos. Su longitud es de 199,287 observaciones, debido a la se distinguieron 49 tipos de avisos distintos que se encuentran detallados en el Anexo (2), debido a las descripciones y la frecuencia con que ocurren demuestran que la gravedad de los avisos es menor a de las alarmas.

**Mantenciones:** Contiene un registro de las mantenciones realizadas por la empresa, con la especificación de la duración y fecha realizada. Se cuentan con 13 instancias de mantención, de las cuales solo 7 son efectivas para el análisis ya que pertenecen al marco temporal. De las fechas se extrae que estas no se realizan de forma periódica, ocurriendo en intervalos de tiempos variables entre una y otra.

**Producción:** Con una longitud de 3,676,125 observaciones, esta base de datos muestra los ritmos de producción registrados por la máquina a lo largo del tiempo.

Tanto la base de datos como la avisos seguía un patrón de registro el cual consiste en escribir horizontalmente la ocurrencia de varios eventos que ocurrieron en un intervalo de tiempo, cada una de ellas podía registrar hasta 10 eventos. Con el propósito de individualizar las ocurrencias se generó una nueva base de datos con un registro vertical, incluyendo las siguientes variables:

- **UNIX\_T:** El “tiempo Unix” o “marca de tiempo Unix” se refiere a una forma particular de representar el tiempo en sistemas operativos tipo Unix, como Linux. En esta representación, el tiempo se mide en segundos transcurridos desde un punto de referencia específico conocido como el “epoch” o “época” de Unix. El “epoch” de Unix es el 1 de enero de 1970 a las 00:00:00 UTC (Tiempo Universal Coordinado).
- **Tipo:** Esta variable fue creada al juntar las dos bases de datos para indicar si la ocurrencia de la fila corresponde a una Alarma o Aviso.
- **Descripción:** Indica los tipos de avisos o alarmas que existen.
- **CAUSA:** Es una variable de los datos de alarmas que indica el origen de la alarma, de estas pueden existir 6 tipos mencionados anteriormente.
- **FECHAHORA:** Entrega el año, mes, día, hora, minuto y segundo exacto en que se guardó la información.

La disposición vertical nos permitió juntar en una sola base de datos la información tanto de avisos, alarmas, mantenciones y producción, la cual se ordenó en base al tiempo para tener una visión temporal. Esto permitió plantear la siguiente hipótesis frente a la definición de una falla, una falla es una alarma o aviso de alta gravedad que perjudica los niveles de producción.

**Status:** Esta base de datos, contiene un registro del funcionamiento de la máquina, es decir, su contenido de 71,503 observaciones muestra los distintos status operacionales de la empresa. En particular esta base para

demostrar el funcionamiento de la máquina, cuenta con 21 descripciones del cambio en el funcionamiento de la máquina. Además, la base cuenta con una columna llamada MACRO, en la que se registra de que forma cambia el status de la máquina, entra las posibles macros encontramos: “STOP”, “RUN”, y “PAUSA”. Las cuales hacen referencia a, que la máquina no se encuentra funcionando, la máquina esta en funcionamiento, y que la producción de la máquina esta en una pequeña pausa respectivamente.

## 4 Discusión Metodológica

En la sección de Discusión Metodológica, se ha llevado a cabo un análisis exhaustivo de la literatura, centrándose en las metodologías empleadas para abordar problemas similares al nuestro. Se han comparado las fortalezas y debilidades de estas metodologías y se ha destacado la necesidad de identificar objetivos y enfoques específicos para adaptar y probar diversas metodologías en el contexto de nuestro problema.

### 4.1 Metas e Indicadores clave

A partir de los datos entregados, es necesario identificar aquellos avisos y alarmas que generan un mayor impacto en la productividad de la máquina, es decir, aquellas situaciones en las que la productividad de esta baja considerablemente. Para esto, se identificarán correlaciones entre los distintos tipos de alerta y las fechas de mantenciones efectivas que se tienen a la fecha. Esto tiene el propósito de generar una política de mantención, con la cual se puedan predecir las mantenciones y evitar una baja en la producción debido a problemas operacionales.

Para poder ir testeando el desempeño de los modelos que probaremos, definimos una serie de indicadores (KPI's) con el fin de detectar anomalías, continuidades y/o alertas tempranas. Estos nos permitirán ir comparando los resultados que entreguen las distintas metodologías y así poder escoger aquella que se ajuste de mejor manera a nuestros datos.

- (a) Tasa de avisos y alarmas diarias.
- (b) Tiempo de actividad en producción (estacionalidades).
- (c) Diferencia de Capacidad Real vs. Capacidad Propuesta.
- (d) Litros desperdiciados de vino.
- (e) Tasa de productos defectuosos.

A partir de estos KPIS se podrá comprobar la efectividad operacional de la solución entregada, se espera que la tasa de avisos y alarmas disminuya, y los otros indicadores aumenten. En la medida que se efectúe la predicción existirán otros tipos de KPIS que ganan protagonismo como son el porcentaje de acierto, porcentaje de error y diferencia entre el valor predicho y el real, estos valores miden la efectividad de la predicción y permiten conocer el estado actual del modelo frente a la realidad, permitiendo a través de esta evaluación del rendimiento tomar decisiones frente a mejorar los comportamientos actuales o iterar en la metodología. Los dos últimos KPI son métricas para medir la efectividad y precisión de su solución con respecto al espectro real, esto sirve para indicar cualitativamente cómo se sabe que tan alejada está la propuesta con respecto al caso real.

### 4.2 Método de Redes Neuronales Recurrentes

Una red neuronal recurrente (RNN) es un tipo de modelo de redes neuronales diseñado para trabajar con datos secuenciales o series temporales en sistemas dinámicos no lineales. Estas redes utilizan datos de entrenamiento junto con técnicas algorítmicas de gradiente descendente para aprender patrones, ya que utilizan información previa para generar respuestas. En otras palabras, las RNN tienen elementos de entrada y salida que están conectados a través de conexiones recurrentes. En el caso de las bidireccionales, estas conexiones les permiten capturar información futura y mejorar sus predicciones mediante un proceso de retroalimentación. (Bonet, I., Et. Al., 2007)

Lo que hace que las RNN sean especialmente poderosas es su capacidad para recordar información pasada gracias a su memoria interna, lo que les permite generar el resto de una secuencia incluso cuando no la conocen de manera completa. En el contexto específico de las RNN, cada neurona puede estar conectada con cualquier otra, y estas conexiones recurrentes pueden formar ciclos en el grafo definido por las

interconexiones de las unidades de procesamiento. Esto les permite descubrir patrones temporales, como estacionalidades, en las secuencias que procesan. (Pérez, J., 2021)

Cuando se aplica este enfoque a un problema como el de una línea de embotellado, se vuelve especialmente relevante debido a su capacidad para lidiar con la no linealidad inherente al proceso de producción, su adaptabilidad para ajustarse a cambios en la operación y su capacidad para tolerar fallas sin interrupciones significativas. Esto se justifica aún más cuando se dispone de datos históricos secuenciales, como registros de avisos y alarmas a lo largo del tiempo, y un conjunto de datos relativamente grande recopilado durante un período de 20 meses permitiendo así estudiar profundamente la dimensionalidad del tiempo.




Figure 1: Redes Neuronales Recurrentes en el tiempo. Fuente: Torres, J (2019).

Según se muestra en la figura 1, existen 4 neuronas interconectada a lo largo del tiempo, cada una de estas la entrada del nodo anterior, como también, su propia salida del instante de tiempo anterior para generar una salida. Llevándolo al problema de línea de embotellado, se utilizan los datos secuenciales a través del tiempo con las entradas que representarían la información recopilada de avisos y alarmas, las conexiones recurrentes son la retroalimentación y respuestas de salida a través del procesamiento de la información, los cuales actualizan el estado interno de la red para así, una vez que ha sido entrenado, pueda capturar patrones, estacionalidades y anomalías y así predecir procesos importantes de la línea. (Torres, J., 2019)

Sin embargo, es importante destacar que las RNN pueden ser computacionalmente intensivas, lo que significa que requieren recursos significativos de procesamiento y memoria para entrenarse y operar de manera eficiente, además que pueden ser afectadas por los “*Exploding Gradients*” o “*Vanishing gradients*” donde los valores de las gradientes para el entrenamiento es excesivamente alto (pendiente) por lo que se produce un error y detención en el proceso de aprendizaje. Dada la gran cantidad de datos con la que se cuenta es importante evaluar el impacto que estos proceso pueden traer a largo plazo a la eficacia del método.

Como antecedente que respalda y otorga valor a la utilización de esta metodología en el mantenimiento predictivo, se han encontrado estudios y tópicos que abordan la misma problemática en otros ámbitos, como por ejemplo, en la industria de la aviación. A partir del análisis lograron llegar a la siguiente conclusión, “Nuestros mejores modelos han sido capaces de detectar entre un 45-55% de los casos anteriormente mencionados correctamente. Esta cifra debe contrastarse con el hecho de que no podemos asegurar que todos los fallos dentro de nuestro conjunto de datos tengan un origen relacionado con los factores climatológicos estudiados. Por tanto, se ha cumplido el objetivo: demostrar el potencial de predicción de estos datos aplicando Deep Learning.” (López, J.M., 2021). Esto valida justamente que para el estudio de mantenimientos predictivos logra ser una herramienta de gran utilidad para abordarlo por Deep Learning mediante RNN.

### 4.3 Métodos de Suavización Exponencial

La suavización exponencial es un método de predicción propuesto durante 1950. En este caso las predicciones se llevan a cabo mediante una ponderación exponencial que decae a medida que las observaciones son más antiguas. De esta forma, los datos más relevantes para generar una mejor predicción son los más actuales. La mayor ventaja que tiene SES es que genera rápidamente un pronóstico confiable, lo cual permite tomar, a su vez, decisiones tempranas. (Hyndman, R.J., & Athanasopoulos, G., 2018)

#### 4.3.1 Método de Suavización Exponencial Simple (SES)

El método de suavización simple se utiliza para series de tiempo sin tendencias evidentes ni estacionalidades periódicas. Se basa en un único parámetro de suavizado llamado “nivel” y pondera los datos históricos de manera exponencial para lograr alta precisión (Vandeput, 2021).



En el contexto de mantenimiento en la línea de embotellado, este método tiene ventajas y desventajas. Entre sus ventajas se encuentra su amplia utilización en el pronóstico de la demanda debido a su sencillez y eficiencia computacional, lo que permite alertas tempranas para reducir el tiempo de inactividad. También destaca su capacidad de actualización en tiempo real.

Sin embargo, presenta limitaciones cuando se trata de series temporales con patrones complejos o cambios abruptos en los datos, como tendencias no lineales. Este problema se agrava cuando se manejan conjuntos de datos grandes. Además, asume que los datos históricos son estables, lo cual no siempre es cierto en la realidad, y no tiene en cuenta factores externos que pueden afectar el mantenimiento. La elección correcta del valor inicial de suavizado es crucial.

En resumen, este método puede ser efectivo como enfoque inicial para los datos, pero no es sostenible a largo plazo debido a su simplicidad y su incapacidad para identificar las causas subyacentes de las fallas, lo que es esencial para mejorar los resultados con el tiempo.

#### 4.3.2 Método Holt-Winters

El método Holt-Winters es una adaptación mejorada de la suavización exponencial simple (SES), especialmente efectiva para series de tiempo más extensas y pronósticos a largo plazo. Matemáticamente, emplea una ecuación de pronóstico y tres ecuaciones de suavizado relacionadas con nivel, tendencia y estacionalidad. Cuando las variaciones estacionales son constantes, se considera un método aditivo; cuando cambian proporcionalmente, se usa el método multiplicativo (Hyndman y Athanasopoulos, 2018).

En comparación con SES, Holt-Winters es más complejo y versátil. Proporciona una visión más profunda de las tendencias a largo plazo y permite la elaboración de pronósticos a corto, mediano y largo plazo. Puede adaptarse a diversos tipos de datos, incluyendo datos categóricos secuenciales con estacionalidades marcadas. Sin embargo, como limitaciones, al igual que SES, no maneja cambios abruptos en los datos y a veces requiere ajustes manuales de parámetros. Además, no considera factores externos, que son relevantes en situaciones con múltiples variables influyentes (Mira, 2018).

#### 4.4 Fast Fourier Transform

La Transformada Rápida de Fourier (FFT) es una técnica que descompone señales en sus componentes de frecuencia, proporcionando información sobre amplitud y fase. Se convierte una señal de dominio de tiempo en una representación en el dominio de la frecuencia, revelando las frecuencias presentes y su energía, denominado "espectro de frecuencia" (Rao, Kim, Hwang, 2010). Esto es útil para identificar patrones y tomar decisiones en aplicaciones de predicción y procesamiento de datos.

Es esencial entender que la FFT se emplea para analizar series de tiempo y señales, descomponiéndolas en componentes de frecuencia. Aunque no predice, extrae información valiosa de las series temporales, siendo útil en el pronóstico de fallas. En la línea de embotellado, ayuda a identificar patrones de frecuencia, detectar ciclos o patrones estacionales en los datos de fallas y proporciona información sobre eventos repetitivos. Sin embargo, tiene limitaciones en la detección de patrones no lineales y depende de la calidad de los datos, siendo menos confiable con datos incompletos.

#### 4.5 Comparación de metodologías

Dado que el objetivo es crear un modelo predictivo de fallas en una línea embotelladora, la elección de la metodología depende de la complejidad de los datos y de la precisión requerida.

Si los datos de fallas son altamente secuenciales y presentan patrones temporales complejos, las Redes Neuronales Recurrentes (RNN) son la elección más adecuada debido a su capacidad para capturar patrones no lineales y adaptarse a cambios en la operación.

Si los datos son relativamente estables y simples, y se requieren alertas tempranas, los Métodos de Suavización Exponencial (SES o Holt-Winters) pueden ser útiles.

El Fast Fourier Transform (FFT) es valioso para analizar patrones de frecuencia, pero no es un método predictivo en sí mismo. Puede utilizarse en combinación con otras metodologías, como las RNN, para comprender mejor los patrones cíclicos en los datos.

En resumen, las Redes Neuronales Recurrentes (RNN) son la elección más prometedora para este problema debido a su capacidad para lidiar con la no linealidad inherente, adaptarse a cambios y manejar datos secuenciales. Sin embargo, es importante evaluar el costo computacional y considerar las limitaciones mencionadas.

## 5 Análisis de datos

En el proceso de análisis de datos, además de realizar una observación general de las bases de datos, se consideró esencial la creación de gráficos que representaran de manera visual la relación entre diversos parámetros seleccionados. Esto permitió obtener una comprensión más clara y dinámica de cómo se comportan los datos a lo largo del tiempo, y facilitó la identificación de patrones y tendencias.

### 5.1 Frecuencia

Para adentrarnos en este análisis, optamos por confeccionar gráficos de frecuencia que representaran las ocurrencias totales de las distintas alarmas y avisos. Estos otorgan una visión general de los datos en todo el período de tiempo de análisis. Este enfoque nos permitió identificar cuáles de estos eventos eran más recurrentes a lo largo de la serie temporal. Dado que nuestro objetivo principal implica la creación de un modelo predictivo, es necesario contar con una amplia cantidad de datos para comprender el comportamiento de la máquina en cuestión. En consecuencia, decidimos iniciar nuestro análisis enfocándonos en los eventos más recurrentes en nuestra base de datos, ya que son estos los que aportan una mayor cantidad de información.




Figure 2: Frecuencias de cada alarma.

Del gráfico se distingue claramente que existen 3 tipos de alarmas las cuales poseen una mayor frecuencia estas son las siguientes: “Falta cera en botella”, “Avería sonda presión sonda” y “Volante no en reposo”, con las frecuencias correspondientes a 971, 829 y 713 ocurrencias respectivamente. Además, se observa que existe una gran cantidad de alarmas que su ocurrencia esta muy por debajo de las 250 ocurrencias, aún más específico 18 tipos de alarma no poseen más de 10 ocurrencias en la totalidad del periodo de análisis.

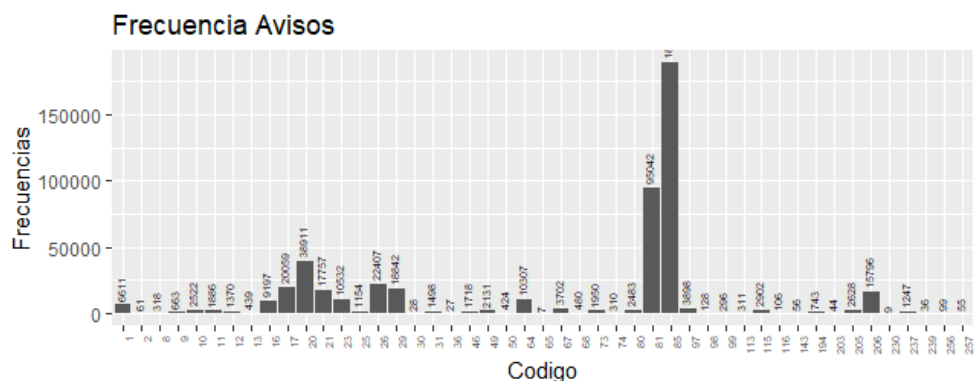


Figure 3: Frecuencias de cada aviso.

A primera vista se puede ver como las frecuencias de los avisos se disparan en comparación a la ocurrencia de las alarmas alcanzando valores por sobre los 1000 en más del 50% de los tipos de alarmas, específicamente en 28 tipos de 49. Los 3 tipos mas recurrentes de avisos son Control automático ventilador campana,

Modulación entrada producto equivocada y Señal bloqueo botellas activada en linea con una frecuencia de 189181, 95042 y 38911 respectivamente.

Como se observo de los gráficos anteriores, la frecuencia de los avisos es superior a la de las alarmas en gran medida. Con el objetivo de visualizar la relación entre la cantidad de alarmas y avisos totales en el tiempo se realizo el siguiente gráfico:




Figure 4: Cantidad de avisos y alarmas por semana.

Este gráfico demuestra que en todo el periodo de tiempo la cantidad de avisos es superior a la de alarmas. Además, por el nivel de detalle alcanzado para los avisos se ven grandes fluctuaciones en periodos del tiempo identificados que es interesante analizar.

Del análisis de frecuencia quedan instancias de análisis abiertas como es ver la relación de las alzas y descensos de cantidad de avisos en un instante de tiempo con la realización de una mantención. Por otro lado, si bien es importante ver cuales son los eventos más frecuentes se debe estudiar el tipo de alarma de menor frecuencia en relación a los ritmos de producción ya que se puede dar el caso donde una alarma o aviso es de gran gravedad y altera inmediatamente el proceso productivo.

## 5.2 Avisos y Alarmas

Teniendo en cuenta cuales son los eventos con mayores frecuencias, tanto para las alarmas como para los avisos, se verificó el comportamiento de los 10 eventos con mayor frecuencia en ambas categorías a lo largo de la serie de tiempo, para identificar como estos se relacionan con las fechas de las mantenciones, y evaluar si aquel evento afecta de alguna manera la producción en la linea de embotellamiento.




Figure 5: cantidad de avisos por día para los 10 mas frecuentes y mantenciones.

Se puede observar en los gráficos anteriores diversos comportamientos. Por una parte hay eventos que no parecen tener ningún tipo de correlación con la cercanía al momento de una mantención (líneas punteadas verticales) como son los avisos “Cambio de velocidad en la máquina ” o de “Bloqueo automático”, esto puede ocurrir debido a que son avisos que no perjudican el funcionamiento de la máquina. Por otro lado se observa que hay avisos cuya frecuencia tiene un grado de correlación con la cercanía de las mantenciones, por ejemplo el aviso “Control automático ventilador”, vemos que su frecuencia va al alza hasta la mantención y posteriormente desciende, este fenómeno da indicios de que ese aviso es un factor de alerta de una falla, si es que el mantenimiento cercano es correctivo.




Figure 6: cantidad de alarmas por día para las 10 mas frecuentes y mantenciones.

En el gráfico anterior, se logran identificar diferentes comportamientos con respecto a las fechas de las mantenciones. Hay ciertas alarmas que su frecuencia si presenta una correlación con las mantenciones (aumenta previo a la fecha y posteriormente disminuye). Por otro lado, hay grupos de alarmas cuya frecuencia es independiente de la presencia de una mantención. El comportamiento de una alarma específica, previo a una mantención, es de gran utilidad porque permite verificar si se realizó mantenimiento correctivo o preventivo, lo que permite clasificar el tipo de alarma como un posible factor que puede producir una falla, en caso de que el mantenimiento sea correctivo.

Continuando con el análisis, se graficó la cantidad de alarmas totales por día, con el objetivo de corroborar si el comportamiento particular de las alarmas anteriores con las mantenciones se asemeja al comportamiento general de las alarmas y estas fechas particulares, las cuales están demarcadas por líneas verticales en los gráficos.




Figure 7: Cantidad de alarmas por día y mantenencias realizadas.

Si bien en algunas mantenencias se logra identificar el comportamiento esperado que refleja un alza de las frecuencias justo antes de la fecha y un descenso posterior a esta, lo cual permite inferir que la mantención solucionó la falla; también se observa la existencia de un desfase entre el alza y la baja con las mantenencias, por lo que se ha optado por trabajar con el comportamiento a nivel individual para no perder información relevante.

### 5.3 Producción




Figure 8: Producción de botellas de vino acumuladas y mantenencias.

El gráfico muestra la cantidad de botellas acumuladas en todo el periodo de tiempo. En su generalidad el crecimiento es estable, pero se logran identificar pendientes que dejan en evidencia la presencia de inestabilidades interesantes para el análisis.

Se puede ver que en la parte central de la gráfica, entre la cuarta y quinta mantención, hay una zona con una pendiente muy positiva, lo que significa un gran volumen de producción en una menor cantidad de tiempo. Dada la gran cantidad de valores, se decidió trabajar con la información diaria para poder simplificar el análisis.

## 5.4 Status

Como se comentó en el apartado de exploración de datos, esta base de datos tiene información sobre el estado de funcionamiento de la máquina. A la hora de analizar esta base de datos surgieron un par de hipótesis. La primera de estas, fue la idea de que luego de una mantención, la frecuencia de paradas de la máquina (lo que se puede ver en la base de datos en observación cuya variable macro es STOP o PAUSA) disminuiría. Para confirmar o rechazar esta hipótesis, se tomó en cuenta solo las paradas que pueden producir una falla, para esto se calificaron las descripciones de status de la máquina, en operaciones rutinarias y no rutinarias tal y como se puede ver en el Anexo (4). Luego de realizar esta clasificación se graficó la relación entre la frecuencia de estas paradas con respecto al tiempo, para comprobar esta hipótesis. Tomando como ejemplo el siguiente gráfico:

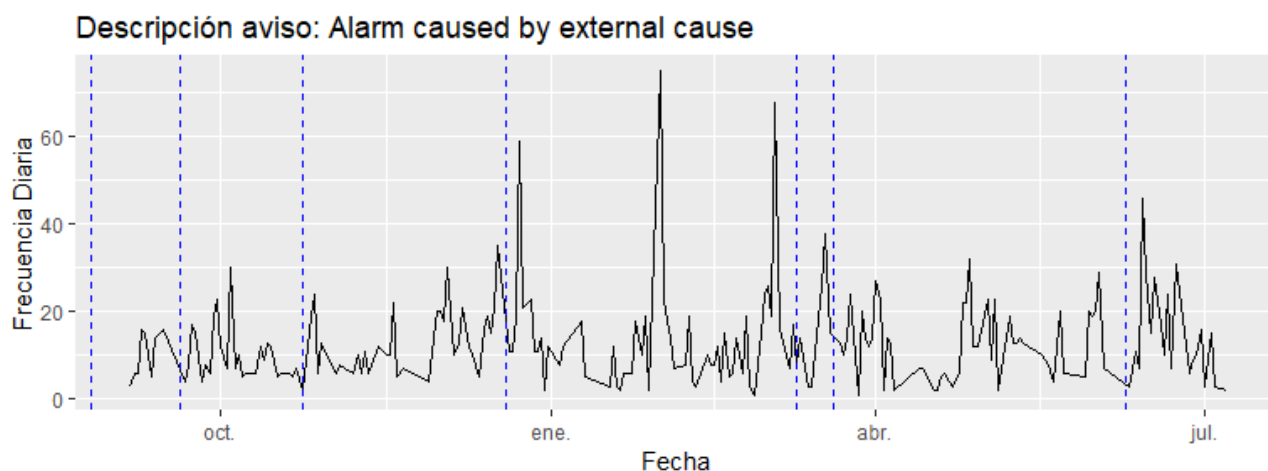


Figure 9: Frecuencia STOP por causa externa

Como se observa en el gráfico, para este tipo de STOP, se puede comprobar que luego de una mantención de la máquina la frecuencia de las paradas de ésta por causas externas tiende a disminuir, cabe mencionar que este comportamiento no es común para todas las paradas que se definieron como “NO” rutinarias, como se muestra en los gráficos del Anexo (6), es por esto que la hipótesis planteada no puede ser aprobada.

## 6 Metodología

La recopilación de información junto al análisis de datos que se ha desarrollado, nos permite definir una línea de acción o metodología para la búsqueda de una solución a la problemática. El diseño y desarrollo para la creación de un modelo predictivo para la línea de embotellado se dividirá en dos etapas fundamentales: estudio de los datos y generación de un modelo de predicción.

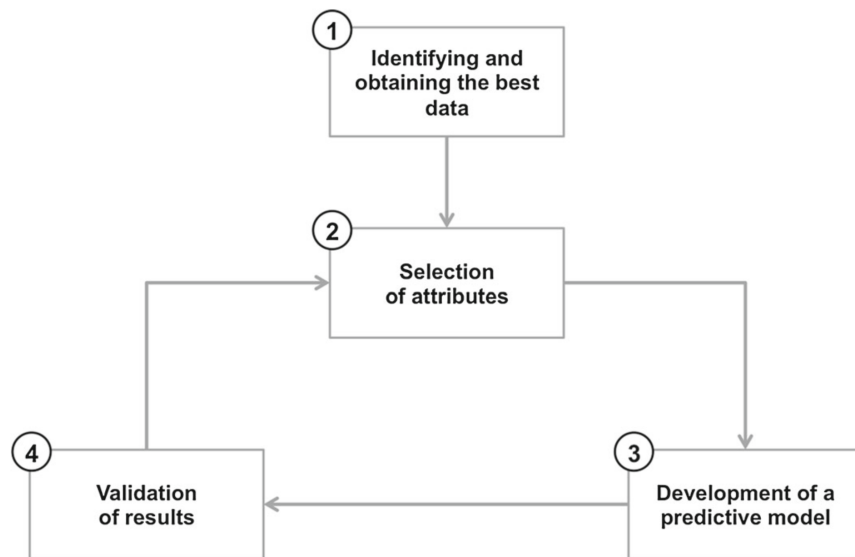


Figure 10: Etapas del proceso de construcción de un modelo predictivo. Fuente: ResearchGate

## 6.1 Estudio de los datos

El estudio se basa en el entendimiento y manejo de la información proveniente de las distintas bases de datos. El objetivo principal que tiene esta etapa es entender las relaciones existentes en la data para posteriormente trabajarlas mediante algoritmos o métodos que nos permitan obtener proyecciones a futuro a partir de los datos históricos.

Para manejar el gran volumen de información con el que contamos hemos definido el siguiente “paso a paso” para poder clasificar y agrupar.

- (a) Trasformar los datos a series de tiempo
- (b) Clusterizar avisos y alarmas
- (c) Identificar detenciones de la máquina
- (d) Determinar correlaciones del análisis gráfico
- (e) Evaluar correlaciones con herramientas estadísticas

### 6.1.1 Definición de Falla

Para poder definir cuales son aquellas situaciones graves para la máquina es necesario definir claramente qué es una falla.

Como ya se mencionó anteriormente, la máquina funciona como monoblock, es decir en ella se llevan a cabo todas las etapas por las que pasa la botella de vino desde que está vacía hasta que está lista para ser empaquetada y distribuida. De esta forma, una falla es todo aquel evento que daña la botella o que genera pérdidas de vino.

En base a la información con la que trabajamos hemos podido identificar que existen una serie de avisos y alarmas que caen bajo esta descripción, las cuales se encuentran listadas en la tabla 6 del anexo, por lo que hemos identificado, a su vez, que no existe una jerarquía de gravedad en cuanto a estas clasificaciones, es decir, una alarma no es más grave que un aviso y viceversa. Además, la frecuencia o cantidad de ocurrencias de estos eventos no determina su gravedad. Esto significa que una mayor ocurrencia de un evento no genera automáticamente una falla porque pueden haber eventos que ocurran una sola vez que tengan una gravedad alta.

Es importante destacar que estos eventos son errores que no se clasifican como operativos, en otras palabras, corresponden a situaciones ajenas al funcionamiento regular de la máquina. Por ejemplo, la alarma “Falta cera en botellas” no clasifica dentro de la definición de falla porque la máquina debe contar con cera para su operación natural.

Complementario a la definición base de lo que es una falla, estas también se caracterizan por generar los STOPS y por lo tanto, requieren de mantenimientos correctivos, los cuales buscamos evitar.

### 6.1.2 Relaciones extraídas

En la sección 5 de “Análisis de datos”, se estudió gráficamente la relación existente entre avisos, alarmas, status y producción con las mantenciones. Se pudo observar un comportamiento de alzas de las frecuencias previo a las mantenciones y disminuciones después de las fechas de estas.

Lo anterior, en conjunto con nuestra definición de falla facilitará la búsqueda de aquellos avisos o alarmas que generan las detenciones.

Con esto podremos definir un umbral máximo de ocurrencias a modo de evitar que la máquina llegue a un “peak” y se detenga, requiriendo de un mantenimiento correctivo.

### 6.1.3 Caso base

A partir del análisis gráfico de los datos y la lectura de las descripciones de cada una de las alarmas, avisos y de los status, pudimos identificar dos eventos que clasifican dentro de la definición de falla y su ocurrencia es catastrófica para la máquina. Estos avisos son “Máquina ligeramente desfasada” y “Máquina desfasada”.

La importancia de estos avisos radica en que la máquina cuenta con una cinta principal que transporta las botellas y las traslada desde una etapa a la otra. Una descoordinación de la cinta con otras partes, como lo son los inyectores de vino o la zona de puesta de tapas, puede generar pérdidas de vino o rupturas de botellas.

Se logró evidenciar que la frecuencia de estos avisos a lo largo de todo el rango temporal es bastante baja, tendiendo un total de 7 ocurrencias para el caso de “Máquina ligeramente desfasada” y 6 para “Máquina desfasada”.

### 6.1.4 Correlaciones

En base al objetivo fundamental del proyecto, el cual es predecir la ocurrencia de fallas en la línea de embotellamiento, es que se requiere conocer la relación entre las variables involucradas. Esto permite estudiar el comportamiento de los distintos eventos que ocurren en forma conjunta, dando la oportunidad de analizar causalidad entre unos y otros. Para esto se realizaron 2 tipos de análisis, que se detallarán a continuación, los cuales se resumen en estudio de autocorrelaciones y estudio de correlaciones entre variables.

#### (a) Autocorrelación

Por la conformación de los datos y el funcionamiento de la máquina se sabe que en un día normal se emite una gran cantidad de avisos y alarmas de los cuales debido a la gravedad generan distintos comportamientos como pausar la máquina (PAUSA), poner en marcha la máquina (RUN) y detener la máquina por un periodo de tiempo más largo (STOP). Estos 3 status mencionados son indicadores de problemas en el funcionamiento, por lo tanto un indicador de estar presente a una falla. Por lo cual nos interesa analizar su comportamiento en el tiempo.

Básicamente la definición de autocorrelación “trataría de explicar la relación que existe en la memoria de la serie observada a través del tiempo” (Gutiérrez, 2021), en este caso se utilizó la función `acf` de RStudio, esta función entrega un gráfico en donde en el eje x se tiene el LAG que en base a los datos entregados que son series temporales consiste en el desplazamiento de la serie temporal en días y en el eje y el coeficiente de ACF o de autocorrelación. Para cada uno de los status mencionados se obtuvieron los siguientes gráficos:






Figure 11: Autocorrelación para el estado de la máquina PAUSA

Este gráfico muestra como la ocurrencia de pausas en un periodo de tiempo afecta las pausas en otro periodo de tiempo, se observa que entre los 0 y 5 lags los coeficientes de correlación se mantienen dentro del rango de precisión definida por las líneas horizontales, más específicamente en el lag 3 indicando que el comportamiento de las pausas se repite en promedio cada 3 días.




Figure 12: Autocorrelación para el estado de la máquina RUN

Para las puestas en marcha es esperable un comportamiento similar al de las pausas debido a que cada vez que ocurre un evento de pausa se intenta volver lo mas rápido posible ala producción normal. El gráfico apoya esto anterior, mostrando que en el lag 3 se estabiliza la función dentro de los limites de precisión, es decir, el patrón de Run se repite cada 3 días.




Figure 13: Autocorrelación para el estado de la máquina STOP

En este gráfico se observa una estabilidad de la serie de tiempo distinta a la de los gráficos anteriores en este caso ocurre entre los lags 5 y 10, mas específicamente en el lag 7, es decir, cada 7 dias se repite el comportamiento de los Stops.

Los 3 gráficos poseen elementos en común como son estabilidades menor a 10 días y una alta correlación entre los primeros 2 días lo cual es natural debido a la ocurrencia de un evento. A pesar de esto, no se logran identificar ciclos claramente definidos que alienten a buscar una predicción a partir de la periodicidad de estos fenómenos, debido a que existen respuestas operativas que justifican los periodos identificados como es el trabajo de turnos semanales para los Stops de lag 7.

(b) Matriz de correlación

En esta parte del estudio se implementaron 3 matrices distintas de correlaciones la primera relaciona los avisos, la segunda las alarmas y la tercera los avisos con las alarmas. Se escogió este método para conocer las relaciones entre variables debido a la gran cantidad de variables involucradas, en específico se deseaba conocer que tipos de avisos y alarmas mostraban dependencia, ya que esto aporta información clave para la predicción de una falla.

De las 3 matrices se calcularon medidas estadísticas básicas, que se muestran a continuación en la siguiente tabla.

	Avisos - Avisos	Avisos - Alarmas	Alarmas - Alarmas
Media	0.135	0.05	0.06
Mediana	0.059	0.011	-0.0047
SD	0.22	0.126	0.1

Table 1: Medidas estadísticas de las matrices de correlación

Los resultados mostrados en la tabla permiten observar la composición general de cada una de las matrices, si bien se esperaban valores superiores a 0.5 para asegurar una correlación fuerte los valores obtenidos en su mayoría se encuentran entre 0,0 y 0,2. Esto gatillo que se analizara de forma particular cada una de las relaciones en busca de resultados significativos. De este análisis surge la justificación de utilizar en conjunto los avisos de máquina desfasada y máquina ligeramente desfasada como caso base, donde se obtuvo un valor de 0.69 para la correlación entre estos avisos además de relacionar entre ellos con otros avisos como son botella caída, velocidad lenta de salida y puertas bloqueadas mostrando la naturaleza de falla al general problemas en la producción que podrían terminar en una ruptura de botella.

Aunque se obtuvo resultados útiles, estos se obtuvieron en su mayoría en base a un trabajo manual el cual es difícil debido al volumen de datos. Esto motivo la búsqueda de otras herramientas como son los clusters que se detallan más adelante, los cuales permiten hacer la agrupación de estos eventos en forma computacional y no manual, de igual forma tener los valores en las matrices permite solucionar dudas puntuales sobre la los datos.

### 6.1.5 Clusterización

Con el fin de extraer más información valiosa a partir del análisis de datos y las correlaciones obtenidas, se decidió realizar clusterización de los datos con el propósito de conseguir subconjuntos de la data y reconocer patrones parecidos entre los objetos, para así, obtener más precisión en la definición de fallas que se mencionó anteriormente. Para este proceso, se aplicó un algoritmo particional, en el cual se eligió una cantidad de clusters relativo a lo que se requería en este estudio, en este caso 4, una vez corrido el algoritmo, se van reasignando iterativamente los objetos entre los grupos hacia la convergencia, asignando todos los grupos a la vez. Además, el método heurístico utilizado dentro del algoritmo es el de “k-means”. Para el caso de la línea de embotellado, el método de k-means calcula el centroide o valor promedio de cada aviso/alarma, para luego definir un umbral de distancia a los centroides que indique cuando el punto está demasiado lejos del centroide y así, poder agrupar cada variable en grupos con patrones similares. Todo esto, con el fin de observar anomalías y señales de fallas de forma gráfica.

Se realizó el proceso de clusterización para avisos, alarmas y combinado entre avisos y alarmas. En esta sección se analizarán los resultados importantes obtenidos para el desarrollo del caso base, el resto de los gráficos se encontrarán en la sección **Anexos**:




Figure 14: Cluster 2 Avisos. Fuente: Elaboración Propia

Número	Aviso (Cluster 2 solo Avisos)
1	IN0052-Señal Bloq. Botellas Activad. de Línea
2	Modulación Entrada Producto Equivocada
3	OUT0204-Lubricación en Curso
4	IN0174-Control Protecciones Delanteras Abiertas
5	IN0047-Señal Lenta de Línea Salida
6	IN0083-Selector Panel de Mando Volante Habilitado
7	Puertas Desbloq.
8	Señal Falta Solicitud lista de CIP
9	IN0274-Control Protecciones Delanteras Abiertas
10	IN0574-Control Protecciones Delanteras Abiertas
11	IN0041-Señal Ftc Paro Ninguna Botella Entrada
12	IN0275-Control Protecciones Traseras Abiertas
13	IN0252-Control Automático Ventilad. 1 Campana
14	IN0475-Control Protecciones Traseras Abiertas
15	Mando Manual Habilitado
16	IN0291-Control Auto. Motor Ajuste Depósito
17	CIP-Señal de CIP de Alarma
18	Elevación en Curso
19	Máquina Desfasada
20	Máquina ligeramente Desfasada
21	IN0476-Control Protecciones Laterales Abiertas
22	OUT0207-Presión Cilindros Demasiado Baja

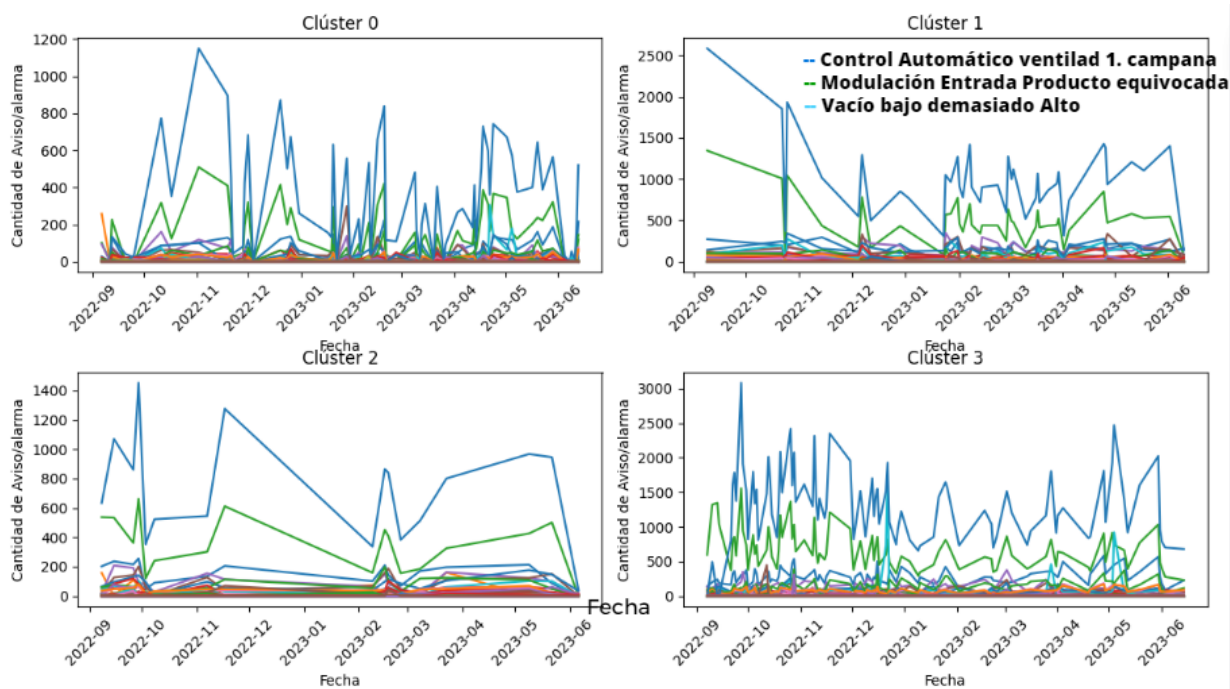


Figure 15: Clusters Avisos/Alarmas. Fuente: Elaboración Propia

Número	Aviso/Alarma (Cluster 2 data combinada)
1	Dbx 27.1
2	Vel. Lenta Seleccionada
3	Bloq. Botellas Activado por Tecla
4	OUT0204-Lubricación en Curso
5	Volante No En Reposo
6	Alimentador Tapones Vacío
7	IN0061-Control Presostato No Gas Inerte
8	Mantenimiento Programado
9	Conteo Botellas Alcanzado
10	IN0047-Señal Lenta de Línea Salida
11	IN0083-Selector Panel de Mando Volante Habilitado
12	IN0474-Control Protecciones Delanteras Abiertas
13	IN0046-Señal Paro de Línea Salida
14	IN0040-Señal Ftc Lenta Ninguna Botella Entrada
15	INA0200-Nivel Máximo Depósito
16	Máquina Desfasada
17	Máquina ligeramente Desfasada
18	IN0476-Control Protecciones Laterales Abiertas
19	OUT0207-Presión Cilindros Demasiado Baja
20	Dbx 27.1
21	IN0171-Control Estrella Salida
22	Falta Cera en Botellas
23	IN0273-Control Rosca Salida
24	IN0071-Señal Emergencia Presionada - vea tab. sinóptica máquina para detalles
25	IN0241-Control Presostato Correa Ventilad. 2 Campana
26	IN0054-Señal Ftc Presencia Botella Caída
27	IN0042-Señal Paro Ftc Acum. Bot. Salida.x
28	IN0574-Control Protecciones Delanteras Abiertas
29	IN0575-Control Protecciones Traseras Abiertas
30	IN0175-Control Protecciones Traseras Abiertas
31	IN0275-Control Protecciones Traseras Abiertas

A partir de los gráficos, se puede observar que hay avisos o alarmas que lideran el comportamiento, lo cual viene dado a partir de que cada agrupación se realiza a partir de una característica en particular. Al estudiar profundamente el detalle de cada cluster, se le presta suma atención específicamente a los avisos: “Máquina ligeramente desfasada” y “Máquina completamente desfasada” los cuales se encuentran presentes dentro del grupo 2 de solo avisos, por lo que se corrobora su correlación y la similitud en los comportamientos de sus series temporales. Con estos resultados, nacen preguntas de reflexión para el análisis de datos: ¿Cómo esto ayuda a predecir y abordar el problema del proceso productivo? Como respuesta, esto ayuda a sustentar la afirmación de que hay avisos que causan fallas catastróficas en la línea de embotellado y no se pueden obviar. A pesar de ser un aviso, conlleva a consecuencias mayores en el proceso, que otras alarmas por lo cual, al aplicar la metodología escogida, es esencial entrenarla con la mayor información y detalle posible para que a partir de la red neuronal, sea capaz de detectar este tipo de avisos y genere un plan de acción correspondiente.

En otras palabras, se emplea un enfoque basado en la recopilación y análisis de una cantidad significativa de avisos generados por la máquina, junto con la identificación de patrones de comportamiento similares a través de los clusters. La premisa fundamental radica en la idea de que las fallas en la línea de embotellado suelen precederse de patrones específicos de comportamiento anómalo, que pueden ser detectados a partir de estos avisos y comportamientos registrados. Al analizar y agrupar estos datos, el modelo busca identificar correlaciones y tendencias que permitan predecir cuándo es más probable que ocurra una falla.

## 6.2 Modelo de predicción:

Esta etapa se enfoca en la elaboración del modelo predictivo, por lo tanto es fundamental el uso de la información obtenida y la elección de una metodología explorada que se ajuste a las características singulares de nuestra problema.

- (a) Testear métodos

- (b) Desarrollo modelo
- (c) Entrenamiento modelo

### 6.2.1 Predicción Mediante RNN

Respecto al uso de los datos, los cuales fueron entregados por el equipo docente, se tomaron consideraciones para la utilización y manejo, así evitar sobreajuste y mejorar la precisión del modelo. Para efectos de esta etapa, se optó en primer lugar por el principio 80/20, donde el 80% de los datos es utilizado para entrenar al modelo, y el 20% restante para validación, esto debido a que se comenzó con una porción seleccionada de datos más pequeña, por lo que la fase de entrenamiento debía cubrir un rango de tiempo mayor para poder obtener un resultado mas exacto. Para pasos futuros, cuando se incluyan todos los datos que aportan información al problema, se utilizará el principio denominado 50/25/25, regla comúnmente utilizada en la predicción y validación de modelos predictivos. Esta regla se caracteriza por el desglose de los datos en 3 grupos, el conjunto de entrenamiento, el conjunto de validación y finalmente el conjunto de prueba (Nieves, 2016). Para comenzar con el modelo predictivo de redes neuronales recurrentes (RNN), se utilizaron dos avisos que están correlacionados; “Máquina Ligeramente Desfasada” y “Máquina Desfasada”. Se pudo concluir que la primera corresponde a una falla de la máquina, y la segunda a un aviso que nos ayudaría a predecir tal falla.

### 6.2.2 Desarrollo y entrenamiento del modelo:

En un principio, como se mencionó anteriormente, se trabajó con los datos combinados del caso base, es decir, los datos sobre “Máquina Desfasada” y “Máquina Ligeramente Desfasada”. Se creó una base de datos que incluía solo estos dos avisos. Se creó el modelo de RNN, con una cantidad arbitraria de epochs y batchs. Se corrió el código varias veces, variando los hiperparametros hasta llegar a una precisión del conjunto de prueba razonable, tal como se recomendaba en la literatura investigada con respecto a RNN.

En primer lugar, se utilizaron 100 epochs y 3 batchs y se graficaron la perdida y precisión que iba obteniendo el modelo en cada uno.




Figure 16: Perdida y precisión de entrenamiento y validación

De la figura anterior, se pudo notar que el modelo se estabiliza a los 40 epochs aproximadamente, por lo que se decidió utilizar esa cantidad. Se mantuvieron los 3 batchs ya que se cuenta con pocos datos para entrenar al modelo, y un número menor introduce más variabilidad en las actualizaciones de pesos en cada paso de entrenamiento. Por esta misma razón, se decidió utilizar un principio 70/30 en lugar de uno 80/20, ya que en los últimos 20 datos que se le entrega al modelo, no se contaba con suficiente información para lograr un predicción exacta.

## 6.3 Validación del modelo

Esta etapa se enfoca en en el análisis y verificación de los resultados obtenidos. El modelo que se utilizó para esta etapa fue de validación cruzada, en su versión mas simple, dado la escasez de datos en el caso abordado se utilizó el último 30% de los datos como conjunto de validación. Este conjunto proporciona una estimación imparcial de como se desempeñaría el modelo ante datos desconocidos. Se realizo un gráfico para mostrar como fue la predicción que entrega el modelo en este conjunto para la ocurrencia de “Máquina Desfasada” a partir de la entrega de ocurrencias de “Máquina Ligeramente Desfasada”.




Figure 17: Comparación de ocurrencias reales y predichas por el modelo

Del gráfico obtenido, se que existe una diferencia notable entre la predicción del modelo y el escenario real, hecho que no preocupa ya que se sabe que la cantidad de datos que se le entrego al modelo no era suficientemente grande para un entrenamiento óptimo. Aunque no se haya obtenido resultados de utilidad, esto se acerca al modelo de RNN al que se espera llegar, a partir de la unificación de el modelo utilizado con los clusters generados. Como parte de validación de modelo, se calcularán los KPI's para medir los niveles de desempeño del procedimiento, lo cual para el caso base no es posible debido a la falta de datos y serán calculados una vez el entrenamiento del modelo sea extrapolado a todos los avisos/alarmas.

## 7 Propuesta de política

La base de datos es un componente fundamental en las operaciones y toma de decisiones. La integridad de los datos es esencial para garantizar que la organización funcione de manera precisa. Para abordar este importante aspecto, se debe de asegurar la implementación de una política que establezca procedimientos claros para la detección y mitigación de fallas en la base de datos. En primer alcance se debe definir explícitamente las fallas en las bases de datos. Actualmente, las bases de datos solo incluyen avisos, alarmas, mantenciones y status, por lo que la información de fallas dentro de esto es nula, y tal como se especificó en las secciones anteriores, hay avisos que causan fallas catastróficas en la línea de embotellado y no se pueden obviar o solo catalogar como avisos/alarmas. De esta forma, definiendo bien cada suceso de la máquina, se evita que se ensucien las bases de datos al catalogar sucesos de forma errónea, donde el mejor ejemplo planteado es el aviso de máquina desfasada.

## 8 Pasos a seguir

Hasta el momento, se avanza significativamente en el proyecto de gestión gracias a la implementación de una carta Gantt. Esta herramienta se ha convertido en la base fundamental para la gestión del proyecto al trazar una línea de tiempo que define los objetivos esperados y el plan de trabajo para todo el equipo. Además, permite establecer dependencias entre las tareas, asignar niveles de importancia y estimar el tiempo necesario para completarlas.

En la primera entrega del proyecto, se logró cumplir con las tareas programadas en el calendario, sin descuidar la ruta crítica. Esto incluyó actividades como el estudio de la literatura y metodología, la exploración de datos, el desarrollo de un caso base y la presentación 1.

En la segunda entrega, el trabajo se concentró en llevar a cabo un análisis más profundo de los datos, implementar una versión simplificada de la metodología, y proponer una política de trabajo que guiará el proyecto en las próximas etapas.

Para las entregas finales del proyecto se espera predecir el comportamiento de las fallas que están pendientes a partir de la utilización de los clusters, que nos proporcionan información relevante sobre factores relacionados a las fallas. A partir de esto se generará un plan de mantención, en el cual se le entregará

a la empresa un plan tentativo de fechas para las mantenencias predictivas y/o un umbral máximo en las frecuencias de avisos y alarmas que permita prevenir una posible falla.

Una vez realizados esos pasos, se analizarán los valores de los distintos KPI's propuestos ya que actualmente no pueden ser medidos por falta de predicción general de las fallas.

Adicional a esto se realizará un análisis de sensibilidad y predicción sobre las mantenencias para testear el modelo frente a las adversidades que puedan existir.

La carta Gantt estará adjuntada en la sección **Anexos**

## 9 Conclusiones

A modo de síntesis, el cambio de enfoque de mantenimiento, pasando de uno preventivo/correctivo a uno predictivo, representa un avance significativo hacia la mejora de las operaciones en la línea de embotellamiento de la empresa vitivinícola en cuestión. Este cambio significaría un aumento considerable en la eficiencia operativa, disminución de detenciones innecesarias, gracias a la optimización de la gestión del mantenimiento, permitiendo cumplir de mejor manera el objetivo de satisfacer la demanda de manera más efectiva.

El análisis de las bases de datos, que abarcan un período de 20 meses y más de 4 millones de observaciones, ha sido esencial en este proceso. Mediante la definición de metas y la identificación de indicadores de desempeño, se encontró el camino para evaluar el desempeño de los modelos predictivos que se desarrollen. Además, la aplicación del principio 50/25/25 para dividir los datos en conjuntos de entrenamiento, validación y prueba, se espera que sea una estrategia efectiva para demostrar y asegurar la solidez de los modelos, y así poder encontrar el que mejor se adapte al problema. Sin embargo es importante recalcar la posible influencia de variables externas en el problema, las cuales pueden llegar a influir en la producción y en las fallas.

El análisis de literatura sobre diversas metodologías, que incluyen redes neuronales recurrentes, métodos de suavización exponencial, el método Holt-Winter, el método de Croston, y el enfoque de SBA y Fast Fourier Transform, nos han brindado una comprensión profunda de cada enfoque en el contexto específico del problema a resolver en nuestra línea de embotellamiento. Entre estas metodologías, se espera que RNN y FFT se adapten de mejor manera al problema, gracias a la capacidad que tienen de trabajar grandes volúmenes de datos variados.

En resumen, en esta etapa, ya se cuenta con un avance significativo, gracias al análisis del caso base e investigación de posibles metodologías, hacia la implementación del mantenimiento predictivo en nuestra empresa vitivinícola, sino que también establece las bases para una gestión más eficiente y rentable de nuestros recursos de mantenimiento. Esto, en última instancia, contribuirá a mejorar nuestra competitividad y nuestro éxito continuo en el mercado vinícola, logrando generar una herramienta de utilidad para la empresa asesorada.



## 10 Referencias Bibliográficas

Bonet Cruz, I., Salazar Martínez, S., Rodríguez Abed, A., Grau Ábalo, R., & García Lorenzo, M. M. (2007). Redes neuronales recurrentes para el análisis de secuencias. *Revista Cubana de Ciencias Informáticas* 1(4), 48-57. Recuperado de: <https://www.redalyc.org/pdf/3783/378343634004.pdf>

Gutierrez, J. M. (2021, junio 10). ¿Qué es la autocorrelación? Test de Durbin-Watson. Todo Econometría y ciencia de datos. <https://todoeconometria.com/autocorrelacion-dw/>

Hyndman, R.J., & Athanasopoulos, G. (2018) Forecasting: principles and practice, 2nd edition, *OTexts: Melbourne, Australia*. <https://otexts.com/fpp2/expsmooth.html> <https://otexts.com/fpp2/holt-winters.html>

Nieves, D. ¿Qué es el escenario de entrenamiento, validación y prueba de conjuntos de datos en aprendizaje automático?. Recuoerado de: <https://es.quora.com/En-el-aprendizaje-automitco>

Mira Segura, L. L., Trejo Martínez, A., & López Cruz, D. (2018). *Aplicación de Holt-Winters para pronósticos de inventarios*. CIENCIA UANL, 21(90). DOI: <https://doi.org/10.29105/cienciauanl21.90-2>

López Camuñas, J. M. (2021). Predictive Maintenance Using Deep Learning. Tesis de grado, Grau d'Enginyeria Informàtica, Facultat de Matemàtiques i Informàtica, Universitat de Barcelona. Recuperado de: [https://diposit.ub.edu/dspace/bitstream/2445/182392/3/tfg\\_josemanuellopez\\_camu](https://diposit.ub.edu/dspace/bitstream/2445/182392/3/tfg_josemanuellopez_camu)

Pérez Ortiz, J. A. (2002). Modelos predictivos basados en redes neuronales recurrentes de tiempo discreto. *Tesis doctoral, Universidad de Alicante* Recuperado de: <https://www.dlsi.ua.es/japerez/pub/pdf/tesi2002.pdf>

Rao, K. R., Kim, D. N., & Hwang, J.-J. (2010). *Fast Fourier Transform - Algorithms and Applications*. Springer Dordrecht. DOI: <https://doi.org/10.1007/978-1-4020-6629-0>

Santa Cruz, R. & Correa, C. (2017). Previsión de demanda intermitente con métodos de series de tiempo y redes neuronales artificiales: Estudio de caso. DOI: <https://doi.org/10.15446/dyna.v84n203.63141>

Soni Madhulatha, T. (2012). An overview on clustering methods. *SR Journal of Engineering*, 2(4), 719-725. Recuperado de: <https://arxiv.org/ftp/arxiv/papers/1205/1205.1117.pdf>

Torres, J. (2019). Redes Neuronales Recurrentes. Recuperado de: <https://torres.ai/redes-neuronales-recurrentes/>

Vandeput, N. (2021). Data Science for Supply Chain Forecasting (2nd ed.). *De Gruyter*. Recuperado de: <https://towardsdatascience.com/simple-exponential-smoothing-749fc5631bed>

## 11 Anexos

### 11.1 Carta Gantt

Para ver la Carta Gantt se debe presionar aquí.

### 11.2 Anexo 1

Codigo	Descripción
0	no asignado
8	IN0070-Señal Bloqueo Inversor Motor Principal
9	IN0071-Señal Emergencia Presionada - vea tab. sinóptica máquina
11	IN0086-Control Sobretemperatura Armario
12	IN0042-Señal Paro Ftc Acum. Bot. Salida
15	IN0096-Control Automático Alimentación Ctrl Nivel/Tapa
16	IN0081-Control Presostato No Hay Aire en Red
21	Error Acoplamiento Tapadora 2
22	Temperatura Máx. Cuba Bombas
24	Conteo Botellas Alcanzado
27	Mantenimiento Programado
30	Error Acoplam. Enjuagadora
31	IN0054-Señal Ftc Presencia Botella Caída
32	IN0064-Señal Mesa Acum. Bot. Llena
35	IN0064-Señal Mesa Acum. Bot. Llena
47	Control Seguridades
48	IN0034-Control Disp. Automáticos Intervenidos Grave
49	IN0170-Control Estrella Entrada
50	IN0171-Control Estrella Salida
52	IN0173-Control Rosca Salida
56	IN0191-Control Automático Extractor Humo
57	IN0180-Control Presostato Tratamiento 1
61	IN0195-Control Auto. Motor Ventilador 1 Campana Enjuagadora
64	IN0196-Control Presostato Correa Ventilador 1 Campana Enjuagadora
65	IN0270-Control Estrella Entrada
68	IN0273-Control Rosca Salida
69	IN0277-Control Botella Colgada
70	IN0294-Control Auto. Bomba Vacío Alto
74	IN0280-Control Cuba Alcohol Desalineada
77	Falta Comunicación PLC Depósito
84	IN0250-Control Presostato Atascamiento Filtro 1 Campana
86	PLC Parado
96	IN0241-Control Presostato Correa Ventilad. 2 Campana
97	IN0470-Control Estrella Entrada
107	IN0454-Control Canal Falta Tapas Pieza Final Paro Máquina
112	IN0467-Control Temperatura No Adec. Pistola Pegamen.
113	IN0570-Control Estrella Entrada
116	IN0573-Control Rosca Salida
121	IN0582-Control Temp. Máx Esterilización Tapas
124	IN0577-Control Botella Colgada

Table 2: Alarmas y sus descripciones parte 1

Codigo	Descripción
126	IN0592-Control Auto. Termorresistent. Esterlización Tapas
129	Botella Rota TV
143	Falta Cera en Botellas
144	Faltan Corchos en Botellas
145	Error Codif. Torreta
153	IN0546-Control Guía Entrada acción.
154	IN0560-Control Patín Gas/Vacío Pos. Trab.
155	IN0517-Control Caja Compresión Abierta
158	Alimentador Tapones Vacío
159	Botella Ausente
200	IN0246-Control Guía Entrada Accion.
205	IN0305-Control Botella Explotada Salida
213	IN0186-Control Presostato Soplado Gotas
218	Dbx 27.1
229	IN0950-Control Alarma Ups
237	INA0000-Falta Ref. Velocidad de Inversor Motor Principal
245	IN0484-Control Bloq. Inversor Motor Cabezales
249	Dbx 31.0
259	IN0954-Control Automáticos Circuitos 480V CA Drive
261	Master
262	Enjuagadora
263	Llenadora
264	Tapadora Rosca
268	Rosca
269	Estrellas Enjuagadora
270	Estrellas Llenadora
282	Dbx 35.1
283	INA0322-Control Seguridad Cubeta
285	IN0320-IN0321-Leva Desc. Conos Delanteros Desalin.
286	IN0230-IN0231-Leva Desc. Conos Recipient. Desalin.
287	IN0230-IN0231-Leva Desc. Conos Recipient. Desalin.
292	IN0234-Control Posición Pirómetro
293	INA0227-Avería Sonda Presión Circuito Vacío Bajo
301	IN0377- Ajuste Auto. Anillo Dispositivos
434	INA0228- Avería Sonda Presión Sondra
444	Generic Cause CG
609	Timeout Solicitado
610	Timeout Fase
613	Volante No En Reposo
628	Temperatura No Mantenido

Table 3: Alarmas y sus descripciones parte 2

### 11.3 Anexo 2

Código	Descripción
0	No Asigando
1	IN0083-Selector Panel de Mando Volante Habilitado
2	IN0081-Control Presostato No Hay Aire en Red
8	Elevación en Curso
9	IN0000-Rotación Solicitado
10	IN0040-Señal Ftc Lenta Ninguna Botella Entrada
11	IN0041-Señal Ftc Paro Ninguna Botella Entrada
12	IN0042-Señal Paro Ftc Acum. Bot. Salida
13	Señal Ftc Lenta Acum. Bot. Salida
16	IN0046-Señal Paro de Línea Salida
17	IN0047-Señal Lenta de Línea Salida
20	IN0052-Señal Bloq. Botellas Activad. de Línea
21	Bloq. Botellas Activado por Tecla
23	Bloq. Botellas Activado por Flujo
25	IN0031-Grasa Bloqueada
26	Vel. Lenta Seleccionada
29	IN0002-Auxiliares No Presentes
30	IN0061-Control Presostato No Gas Inerte
31	OUT0031-Mando Disposit. Engrase
36	CIP-Señal de CIP de Alarma
46	Puertas Desbloq.
49	IN0174-Control Protecciones Delanteras Abiertas
50	IN0175-Control Protecciones Traseras Abiertas
64	OUT0204-Lubricación en Curso
65	IN0291-Control Auto. Motor Ajuste Depósito
67	IN0274-Control Protecciones Delanteras Abiertas
68	IN0275-Control Protecciones Traseras Abiertas
73	INA0200-Nivel Mínimo Depósito
74	INA0200-Nivel Máximo Depósito
80	Primer Llenado en Curso
81	Modulación Entrada Producto Equivocada
85	IN0252-Control Automático Ventilad. 1 Campana
97	IN0474-Control Protecciones Delanteras Abiertas
98	IN0475-Control Protecciones Traseras Abiertas
99	IN0476-Control Protecciones Laterales Abiertas
113	IN0594-Control Auto. Motor Ajuste Émbolos
115	IN0574-Control Protecciones Delanteras Abiertas
116	IN0575-Control Protecciones Traseras Abiertas
143	Faltan Corchos en Botellas
194	OUT0210-Válvula Entrada Producto Cerrada por Falta
203	OUT0207-Presión Cilindros Demasiado Baja
205	INA0227-Vacío Bajo Demasiado Bajo
206	INA0227-Vacío Bajo Demasiado Alto
230	IN0951-Control Ups Funcionamiento de Batería
237	Señal Falta Solicitud lista de CIP
239	Mando Manual Habilitado
256	Máquina ligeramente Desfasada
257	Máquina Desfasada

Table 4: Avisos y sus descripciones

## 11.4 Anexo 3

MACRO	DESCRIPTON	RUTINAL
RUN	"Production Slow caused by selecting the button on operator panel"	NO
RUN	"Production at Nominal Speed"	NO
STOP	"Machine stopped with No anomaly and ready to start"	NO
STOP	"Alarm caused by external" cause	NO
STOP	"Machine on alarm"	NO
STOP	"Alarm that are not categorized as previous anomaly"	NO
RUN	"Production slow caused by Infeed conveyor request"	NO
PAUSA	"Anomaly caused by operator action"	NO
STOP	"Machine stopped because of outfeed Full"	NO
PAUSA	"No phase selected"	NO
PAUSA	"Production ending"	SI
PAUSA	"Time used to accesorie the machine for washing (Dummy Bottle etc)"	SI
PAUSA	(DESCRIPCION vacia)	SI
PAUSA	"Production Preparation"	SI
PAUSA	"Machine preparation at the production phase"	SI
STOP	"Machine stopped because of empty inlet"	NO
PAUSA	"Time used for the change over part (changing format, high regulation etc)"	SI
PAUSA	"Washing stopped because of an anomaly"	NO
PAUSA	"Effective washing Time"	SI
PAUSA	"Waiting time for the CIP Unit"	SI
PAUSA	"Waiting for Morning Restart from CIP Unit"	SI

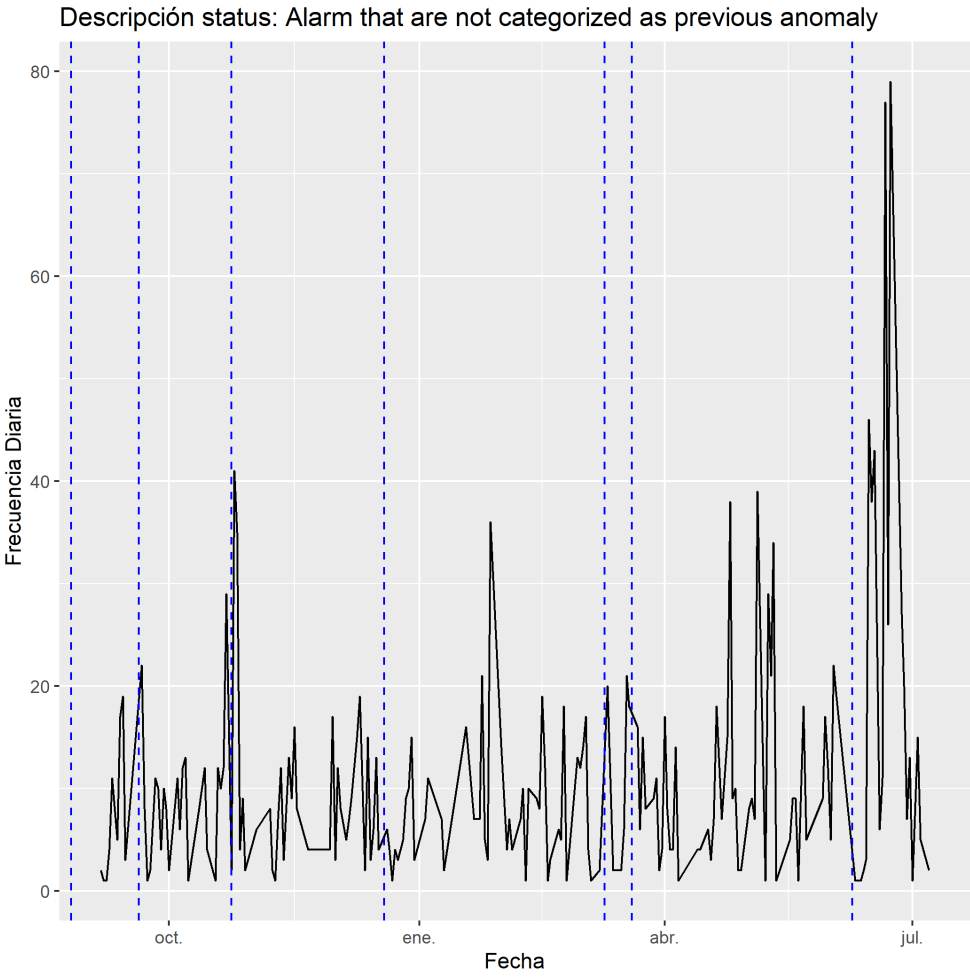
Table 5: Descripciones status máquina

## 11.5 Anexo 4


Codigo	Descripción
8	IN0070-Señal Bloqueo Inversor Motor Principal
9	IN0071-Señal Emergencia Presionada - vea tab. sinóptica máquina
11	IN0086-Control Sobretemperatura Armario
12	IN0042-Señal Paro Ftc Acum. Bot. Salida
21	Error Acoplamiento Tapadora 2
22	Temperatura Máx. Cuba Bombas
30	Error Acoplamiento. Enjuagadora
31	IN0054-Señal Ftc Presencia Botella Caída
32	IN0064-Señal Mesa Acum. Bot. Llena
77	Falta Comunicación PLC Depósito
86	PLC Parado
112	IN0467-Control Temperatura No Adec. Pistola Pegamen.
124	IN0577-Control Botella Colgada
129	Botella Rota TV
143	Falta Cera en Botellas
144	Faltan Corchos en Botellas
145	Error Codif. Torreta
158	Alimentador Tapones Vacío
159	Botella Ausente
237	INA0000-Falta Ref. Velocidad de Inversor Motor Principal
285	IN0320-IN0321-Leva Desc. Conos Delanteros Desalin.
286	IN0230-IN0231-Leva Desc. Conos Recipient. Desalin.
293	INA0227-Avería Sonda Presión Circuito Vacío Bajo
434	INA0228- Avería Sonda Presión Sonda
10	IN0040-Señal Ftc Lenta Ninguna Botella Entrada
11	IN0041-Señal Ftc Paro Ninguna Botella Entrada
12	IN0042-Señal Paro Ftc Acum. Bot. Salida
13	Señal Ftc Lenta Acum. Bot. Salida
16	IN0046-Señal Paro de Línea Salida
17	IN0047-Señal Lenta de Línea Salida
20	IN0052-Señal Bloq. Botellas Activad. de Línea
21	Bloq. Botellas Activado por Tecla
23	Bloq. Botellas Activado por Flujo
25	IN0031-Grasa Bloqueada
46	Puertas Desbloq.
73	INA0200-Nivel Mínimo Depósito
74	INA0200-Nivel Máximo Depósito
81	Modulación Entrada Producto Equivocada
143	Faltan Corchos en Botellas
194	OUT0210-Válvula Entrada Producto Cerrada por Falta
203	OUT0207-Presión Cilindros Demasiado Baja
205	INA0227-Vacío Bajo Demasiado Bajo
206	INA0227-Vacío Bajo Demasiado Alto
256	Máquina ligeramente Desfasada
257	Máquina Desfasada

Table 6: Compilado de avisos y alarmas que se definen como fallas

11.6 Anexo 5 Gráficos frecuencia status




Descripción status: Anomaly caused by operator action







Descripción status: Machine on alarm




Descripción status: Machine stopped because of empty inlet




Descripción status: Machine stopped because of outfeed Full




Descripción status: Machine stopped with No anomaly and ready to start



Descripción status: No phase selected



Descripción status: Washing stopped because of an anomaly



11.7 Anexo 6




Figure 18: Cluster 0 Avisos. Fuente: Elaboración Propia




Figure 19: Cluster 1 Avisos. Fuente: Elaboración Propia




Figure 20: Cluster 2 Avisos. Fuente: Elaboración Propia




Figure 21: Cluster 3 Avisos. Fuente: Elaboración Propia






Figure 22: Cluster 0 Alarmas. Fuente: Elaboración Propia




Figure 23: Cluster 1 Alarmas. Fuente: Elaboración Propia




Figure 24: Cluster 2 Alarmas. Fuente: Elaboración Propia




Figure 25: Cluster 3 Alarmas. Fuente: Elaboración Propia




Figure 26: Clusters Avisos/Alarmas. Fuente: Elaboración Propia